

微型汉语系统的构建及汉语文章的自动生成

程智

(广州大学 教育学院 教育信息技术系, 广州 510006)

摘要: 本文尝试建立一个只包含少量汉字的微型汉语系统, 并用它来研究计算机如何理解汉语句子的意义、汉语词汇的形成规律以及汉语文章的自动生成原理。本文依据比较简单的生态系统来构建这个微型汉语系统, 并将其划分成四个层次。这四个层次分别是物理层、连接层、规则层和表达层。在连接层上, 所有汉字通过句子的学习可以形成相互之间的连接, 并通过句子强度这一参数来判断一个句子的意义。在形成了足够多的句子以后, 利用统计的方法, 将其中出现频率比较高的汉字组合视为由多个汉字组成的词汇。在规则层, 则通过设置各种规则来使系统生成比较长的文章, 达到计算机自动生成文章的目的。从计算机程序运行结果来看, 该微型汉语系统能够正确识别有意义和无意义的句子, 而所生成的词汇也基本上符合现代汉语的习惯。本文也尝试采用 N-gram 模型来解决相同的问题, 结果是令人失望的。最后本文利用该系统生成文章, 虽然从自动生成比较长的文章方面来看, 计算机的能力比较有限, 输出文章格式比较单一, 与人类书写的文章相比, 还存在比较大的差距, 但是从可读性等方面来看, 还是能够达到基本的阅读要求的, 且可改进的空间也很大。从本工作的结果来看, 传统的计算机体系结构在处理自然语言方面还是有很大的潜力可挖的。

关键词: 中文处理; 人工智能; 汉语模型

中图分类号: TP391

On Construction of a Mini Chinese Language System and Automatic Generation of Articles

CHENG Zhi

(Dept. of Educational Information and Technology, Educational School, Guangzhou University, Guangzhou, Guangdong, China, 510006)

Abstract: In this paper, we established a mini Chinese language system that includes only a few Chinese characters in order to make the computer understanding the meanings of the sentences, the formation of Chinese words and how to automatically generate the articles by computer. We build the mini Chinese language systems based on the simple ecological system, and divided it into four layers. The four layers are the physical layer, link layer, rule layer and presentation layer. All the Chinese characters can form the connections between each other through the sentence learning at the link layer. We can also determine whether the computer understand the meaning of a sentence by the parameter of Sentence Weights. After sufficient numbers of sentences have been formed, we can get the Chinese words that composed of multiple Chinese characters from the high frequency Chinese character combinations. The mini Chinese language system can also output the long articles by using multiple rules in the rule layer to achieve the purpose of automatically generating articles by using computer. The Mini Chinese language system can identify the meaningful and meaningless sentences successfully from the results of the experiments. The Chinese words generated by the system are basically in line with the uses of modern Chinese language. We also try to use the N-gram model to solve the similar problem in this work, but we get the worse results. Although the computers abilities in automatically generating articles are relatively limited, the output format of the articles relatively simple by compared with the humans writing articles from the experiment results, but it can achieve the basic reading requirements in terms of readability. It also has a great room for improvement. The results from this work also show that there are a lot of potential to be developed in natural language processing by using the traditional computer architecture.

作者简介: 程智 (1967-), 男, 副教授, 主要研究方向: 现代教育技术、计算机技术、计算机网络. E-mail: gzchengzhi@hotmail.com

Key words: Chinese language processing; Artificial intelligence; Chinese language model

0 引言

该系统目前来看离真实的自然语言系统还有一定的差距。但是面对复杂的自然语言系统,要直接进行处理是比较困难的。因此现在需要做一种抽象工作,即将语言抽象出来,然后构造一个比较简单的模型,再将该模型应用到实际的自然语言环境中。目前自然语言处理工作中,最缺乏的就是这种简洁的模型。它能够反映出语言本身的规律。本工作提供的这种微型汉语模型可以解决这一问题。

这就如同牛顿定律一样,如果仅仅看牛顿运动定律的公式,往往给人太过简单的印象。因为与复杂的自然现象相比,这样的公式有点像是玩具。

另外之所以采用汉语来进行研究,除了本文作者的母语为汉语以外,更重要的是,在所有语言中,汉语有其特有的一些重要的规律。这些规律是其他的语言所不具备的。而之所以形成了这样的独特的语言现象,与汉语长达几千年连续不断的使用和完善有关系。由于中国几千年的历史文化的沉淀,作为中国文化的一个重要组成部分,汉语已经形成了与其他的语言很不相同的特色。特别是“五四运动”以来的新文化运动,白话文的大量使用,使得汉语在构词方法上。采用了一种比西方的语言更加抽象的方法。这为使用计算机技术来进行处理提供了独特的优势。这是在使用其他语言进行研究的时候所不具备的。

中文处理跟西文处理有很大的区别。直观上来看,中文句子的单位为单个汉字,而拼音文字句子的单位则为词汇。尽管从已有的文献中还难以发现跟本研究有直接继承关系的成果,但是相关的研究还是可以作为本研究在某种程度上的基础的。这里尝试着回顾一下部分成果,或许对于理解本研究有一定的启发作用。这些成果表现在:

1. 中文统计语言模型的建立。利用统计语言模型对中文进行研究则随着计算机技术的发展而受到了广泛的重视。目前已经有多种统计语言模型被用来对中文信息进行处理^[1]。比如一些学者利用统计语言模型解决了汉语音字转换的一些问题^[2]。另一些学者则尝试利用统计模型来扩展词典的词汇^[3]。目前统计语言模型在汉字分词和整句拼音输入法中的应用最为广泛^{[4][5]}。中文统计语言模型与本研究的关联度比较大一些。

2. 中文语法分析。随着计算机技术的发展,汉语语法信息的处理技术也得到了迅速的发展。俞士汶等在《现代汉语语法信息词典》库中,通过收集大量的词条语法信息,为利用计算机对汉语语法信息作进一步的处理打下了重要的基础^{[6][7][8]}。曹剑芬等人则从利用汉语语法信息对汉语的韵律结构进行预测^[9]。周强等人尝试实现了汉语自动句法标注系统,并提出了建立大规模汉语树库的想法^[10]。俞士汶在上个世纪八十年代就对中文输入法中语法分析技术进行了研究^[11]。

3. 中文语义分析。

由丽萍等对各种不同的语义分析模型进行了评述^[12]。她们指出目前主要存在三种汉语语义分析模型,分别是词语依存、概念依存和核心依存。例如在詹卫东等为机器翻译建立的词组本位的语义模型中,对不同词性的词汇的搭配进行了分析^[13]。这是一种词语依存的模型。本研究工作与上述文献所描述的工作相比,有比较大的区别。主要表现在本研究是要通过语义分析判断句子的意义以及自动生成可以阅读的句子和文章。而上述文献提供的研究成果则主要是探讨完全自然的语言环境中词语以及概念等的相互依存关系。

与英语不同,汉语语言模型的研究起步比较晚,且因为早期计算机处理多字节字符比较

困难,所以利用计算机来处理和建立汉语语言模型主要还是最近二十年来的工作。在拼音文字的研究中,影响最大的也是统计语言模型。一些公司还专门为统计语言模型开发了相应的软件包。比如 SRILM 软件包^[14]和 CMU-Cambridge 软件包^[15]等。另一些学者也尝试建立了动态模型^{[16][17]}、层次模型^{[18][19]}、相互依存语言模型^[20]、结构化语言模型^[21]、基于相关性语言模型^[22]等其他语言模型。

从已有的研究文献资料来看,国外建立各种不同的语言模型的目的主要在于以下 2 个方面:

1. 语言识别。在语音识别方面,需要建立一个对应的计算机模型,利用这样的模型来比较语言的语音信号,从而获得比较好的语音识别效果。这种语音识别工作可以使用统计语言模型^{[23][24]},也可以使用其他模型,比如动态模型等^[17]。

2. 信息检索。利用统计语言模型来进行信息检索,可以达到更加智能化的要求,并为采用自然语言的方式实现人机对话打下了基础^{[25][26]}。

从这些不同的语言模型来看,各种语言模型都直接面向完全自然的语言环境。然而,由于人类使用的自然语言十分复杂,将这些语言模型直接应用到自然语言环境中,反而将问题复杂化了。要走出目前自然语言处理的困境,通过建立非常小的语言系统,可以有效地减少自然语言处理的复杂程度。在计算复杂程度已经显著降低的情况下,设计相应的程序来理解句子、自动产生有意义的文章将成为可能。

如果实现了一个非常小的微型语言系统,这就类似于各种“微型世界”的研究。对微型世界进行的研究起源则更早。例如,在算法语言方面,利用 Logo 语言构建微型世界^{[27][28]}。在 Logo 语言的环境中,儿童可以通过命令的方式来控制屏幕上的海龟的移动,最终实现在一个很小的环境中来学习数学知识。

当然在计算机程序设计语言中,任何一种程序设计语言都可以看作是一个微型的语言系统。而在这种微型的语言系统中,必须按照一定的语法规则来实现人类与机器之间的对话。

虽然目前程序设计语言已经能够达到更加智能化的层次,并逐渐形成了具有自己的特色的语法系统,但是这种程序设计语言仍然只是一个人类与机器之间相互交流的语言。计算机本身还无法进行思维,自动产生出有意义的程序。这里所说的“有意义的程序”的意思指的是,计算机能够通过自主的学习过程,丰富自己的知识库的内容,并利用已经学习到的知识,产生出能够实现所需功能的程序。

在某种意义上来看,这同自动编程技术有点类似。这种自动编程技术目前在自动控制领域应用的比较广泛。利用计算机技术针对不同的产品自动输出相应的程序,可以提高产品开发的效率。

而在神经网络等技术领域,则利用人工神经元之间的相互连接,通过诸如反向误差传播等算法来调整神经元之间的连接权值,也可以实现根据不同的输入输出结果来实现自动编程的功能。

另外值得注意的是,在自然界以及人工制造的产品之中,也都存在这种相对独立的微型环境。例如个人计算机系统。在个人计算机系统中,包括了硬件和软件两个组成部分。硬件本身可以组成一个相对独立的微型环境。软件也一样。而硬件和软件环境之间又会产生相互作用。

本文所做的工作期望能够构建微型的汉语语言系统,并尝试建立一个具备了层次化结构的语言模型。在这个系统中,只需要少量的汉字,就可以学习、判断、表达这个环境中的各种意义。

1 微型汉语系统的界定

用来表达意义的系统很多,最基本的是语言系统。利用语言系统,人与人之间可以相互交流。除了语言系统以外,自然界和人类社会中还存在其他的用来表达意义的系统。例如数学符号系统可以用来表示变量之间的相互关系。与数学语言系统和自然语言系统相比,计算机语言系统介于数学语言系统和自然语言系统之间。计算机语言系统由各种指令构成。图形符号系统可以利用图解的方式来表达意义。肢体动作符号系统则可以通过肢体的变化来表达某方面的信息。

其中自然语言形成的系统最为庞大,也最为复杂。要直接用来进行可以控制的研究存在很多的困难。通过构建一个微型的语言系统环境,则可以简化自然语言系统的复杂性。微型语言系统可以被用来与计算机程序设计语言系统进行对比,二者有相似之处,但是二者之间的差别也很大。这些差异主要表现在以下几个方面:

1. 计算机程序设计语言系统的语法要求比较严格,处理的是机器语言;而微型语言系统处理的主要是自然语言。

2. 计算机程序设计语言主要采用的是规则,是基于规则的;而微型语言系统则是基于意义和规则的,二者相互结合。

3. 计算机程序设计语言系统应用于机器和机器之间以及人和机器之间的信息交流;而微型语言系统则主要是用来模仿人的大脑的思维过程。

1.1 微型汉语系统的定义

微型汉语系统是那些在时间、空间、对象、关系、程度、属性等方面有明确限制的语言系统。它属于自然语言系统中的一个子系统,只包含了比较少的汉字。在该系统中,可以在逻辑上实现所有的对象之间的相互作用。并用语言通过意义和各种规则的方式完整地描述整个系统所处的各种状态。

微型汉语系统所具备的特点包括:

1. 系统比较小。
2. 包含的对象比较少。
3. 使用的汉字数量比较少。
4. 系统中的所有对象都可以相互之间发生作用而不需要借助外部的因素。
5. 是一个自组织的系统。
6. 具备可扩展性。
7. 包含的词汇量足够,能够采用意义和规则的方式准确地进行表达。
8. 按照对象、关系、程度、属性、时间和空间等限定条件的不同,所形成的微型语言系统的大小会有所区别。

1.2 微型汉语系统的层次

可以将该微型汉语系统划分成4个层次,如图1所示。各层次的含义如下:

物理层:主要涉及到各种物理设备。如计算机、神经网络等。

连接层:用来形成汉字之间的意义连接。

规则层:这些规则可以形成人类能够看得懂的句子或文章。

表达层:将句子或文章表达出来。




图 1 微型汉语的层次结构

Fig. 1 MCS's hierarchical structure

1.2.1 物理层

物理层可以使用多种设备，可以是现有体系结构的计算机，也可以是神经计算机或者是量子计算机等。当然也可以是一个真实的神经网络系统。采用了这样的层次划分以后，微型汉语系统模型可以实现与硬件的分离，从而满足在不同的系统中探讨语言规律所需。

1.2.2 连接层

在连接层中，实现了汉字之间的连接。要获得汉字之间的连接，需要通过适当的运算公式来实现。这里假设语言运算中的最基本运算规则就是“名词+动词+名词”（用 $nv n$ 表示）。其中名词可看作是变量，而动词则视为运算符号。另外定义一个概念——连接强度。所谓连接强度指的是两个汉字结合在一起的强度。

1.2.3 规则层

规则层中包含了多种规则，这些规则包括了语法规则、语义规则、逻辑规则等。

在规则层，利用语法规则，可以获得符合语法要求的句子。通过逻辑规则，则可以获得有意义的句子。通过文章结构的规则，则可以获得完整的文章结构。

1.2.4 表达层

利用表达层，可以将规则层、连接层中形成的意义以特定的方式表达出来。例如利用 Word 文档的形式来表达，或者利用图形的方式等。

1.3 不同语言系统的层次结构实例分析

不同的微型语言系统具备不同的层次结构。

计算机语言系统，以 C 语言为例：

物理层：计算机硬件系统

连接层：机器代码、汇编

规则层：C 语言语法规则

表达层：C 语言编辑器

更复杂的计算机语言：Java

物理层：计算机硬件系统、机器代码、汇编

连接层：Java 虚拟机

规则层：Java 语言语法规则

表达层：Java 语言编辑器

这是一种采用了更复杂的方式来执行的程序设计语言。

200 从上述两种程序设计语言来看，每一个层次都是为了屏蔽下一个层次的技术，使之透明化。而这种透明化也意味着，可以在其基础上使用不同的方式来构造语言系统。

自然语言（英语）

物理层：字符、发音

连接层：词与词之间意义联系

205 规则层：语法规则、句子规则、篇章规则

表达层：语言表达方法

自然语言（汉语）

物理层：字符、发音

连接层：字与字之间的意义联系

210 规则层：构词规则、语法规则、句子规则、篇章规则

表达层：语言表达方法

由汉语和英语的层次结构可以看出，英语与汉语的区别在物理层和连接层这两个层次已经有比较明显的表现。在物理层上，英语的单位为单词，而汉语的单位为汉字。当然白话文中也尝试将词组作为单位，但实践中的应用出现了严重问题，这就是在句子中如何进行“划词”问题。目前已经有了很多的文献涉及这方面的问题。

215 而在连接层中，英语的连接表现为单词与单词之间的连接。而汉语中表现为汉字与汉字之间的连接。

这可能反映出两种语言的基本区别。这些区别进一步也会影响到规则层和表达层，并导致这两种语言出现差异。比如在汉语的规则层中还存在构词规则。

220 例如在语法方面，汉语语法与英语语法存在一些比较重要的区别。例如汉语中存在非常复杂的补语用法，而英语则比较少见。

在表达层中，英语可能以发音为主，而汉语则可能以视觉为主。

微型汉语系统

物理层：计算机系统

225 连接层：字与字之间的意义连接 ‘在连接层上能够判断句子的意义

规则层：语法规则、句子规则、篇章规则 ‘在规则层上能够构造文章

表达层：文本表达方式

与自然语言系统相比，微型汉语系统的汉字数量比较少，且语法规则等各种规则的集合比较简单。

230 在微型汉语系统的四个层次中，其中物理层和表达层可以使用已有的技术来实现。比如计算机、系统软件等。本文所需要做的工作在于构造合适的连接层以及规则层，以便能够输出有意义的句子和篇章。

2 微型汉语系统模型的构建

235 从 1.3 中描述的微型汉语系统的层次结构来看，物理层和表达层可以采用不同的计算机系统，甚至可以使用未来全新的计算机系统。构建微型汉语系统所需要做的主要工作为在连接层上构造合适的算法，以及在规则层中构造合适的规则。

2.1 微型汉语系统的连接层的算法

由于系统比较小, 结构比较简单, 在微型语言系统中, 利用名词作为变量, 动词作为运算符号, 就可以实现连接层的功能。

无论是英语系统中以单词为单位还是汉语系统中以单个汉字作为单位。意义的连接都有一个基本的特点, 就是必须具备“对象”和“动作”这两个最基本的因素。这也是构成句子的最基本“主谓”结构的基本要求。就是说要用语言来表达意义, 该语言的句子必须包含“对象”和“动作”这两个基本的因素, 才称得上是有意义的完整的句子。

进一步分析, 即便是最简单的“主谓”结构的句子, 其实也隐含了“动作”的作用对象。比如句子“我走了”, 其中“走”为动作, 隐含的作用对象为“路”。但由于“走路”是大家熟悉的用法, 省略掉, 别人也可以很容易理解该句子的含义。另一个相反的例子则可以证实这一分析的正确性。比如我们可以说“我上路了”, 也是相同的含义。但是由于“上路”还可能其他的歧义, 该句话就不能够简略为“我上了”。

因此在本文构造微型汉语系统的时候, 采用“对象+动作+对象”的结构。对应了基本的“主谓宾”的句子结构。

而由这样的结构形成句子中“字”或“词”之间意义的连接。这样的意义连接表现在 4 个方面, 分别是:

1. 句子中所有元素之间意义的整体连接。
2. “对象”如何使用“动作”的意义连接。
3. “动作”如何作用与“对象”的意义连接。
4. 两个“对象”之间的意义连接。

2.1.1 实现意义连接的算法

假设有一个由三个汉字组成的最简单的句子, 符合“对象(名词)+动作(动词)+对象(名词)”结构的要求, 可用字母表示为 AVC。

其中 A 和 C 为名词, V 为动词。

在系统刚刚建立起来还没有学习任何句子的时候, 只有动词 V 包含了两个最基本属性, 分别是前置属性 F 和后置属性 B。

一旦系统学习了该句子以后, 三个汉字可以通过结合动词前置和后置属性来获得自己的属性。

结合以后的前置属性为 AF, 后置属性为 CB。

若一个名词或动词 X 的第 i 个属性用 $S_i(X)$ 表示, 且通过数字 0 和 1 来表示名词在句子中的位置。如果该名词在句子的前面, 则位置为 0, 在后面的则位置为 1。另外为了便于程序的处理, 动词的位置则用 m 表示。对应汉字或词汇出现在句子中的位置用 $W_i(X)$ 表示。经过学习以后, 各汉字或词汇的属性变化情况如下:

A 的属性改变为: $S_1(A)=AF; S_2(A)=CB; W_1(A)=0 W_2(A)=0$

C 的属性改变为: $S_1(C)=AF; S_2(C)=CB; W_1(C)=1 W_2(C)=1$

V 的属性改变为: $S_1(V)=F; S_2(V)=B; S_1(V)=AF; S_2(V)=CB; W_1(V)=m W_2(V)=m$

2.1.2 句子强度的计算

判断一个 nvn 结构的句子是否能够形成完整的连接, 可以通过计算该句子总体的连接强度(简称为“句子强度”)来实现。句子强度由以下几个部分构成:

(1) 语法结构强度

如果符合特定的语法结构, 比如符合 nv_n 等结构, 则句子强度增加。

$$P_{gram} = 1 \dots\dots\dots (1)$$

280 否则该项为 0。

(2) nv_n 结构强度

如果主语名词 A、动词 V 和宾语名词 C 的属性中具备了相同的属性, 比如上述例子中, 都具备了 AF 和 CB 属性。且主语名词和宾语名词的这两种属性的位置分别为 0 和 1, 这样该句子的句子强度将增加。

285 在连接层中形成的句子强度计算公式如下:

设 $S_i(X)$ 表示汉字或词汇 X 的第 i 个属性, $W_i(X)$ 表示第 i 个属性所在的位置。则符合语法要求的句子强度计算可以采用下面的公式:

$$P_{nn}(AVC) = \sum_{i,j,k} \delta_{S_i(A), S_j(V), S_k(C)} \cdot \theta[W_k(C) - W_i(A)] \dots\dots\dots (2)$$

其中:

$$290 \quad \delta_{S_i(A), S_j(V), S_k(C)} = \begin{cases} 1 & S_i(A) = S_j(V) = S_k(C) \\ 0 & \text{其他条件} \end{cases}$$

$$\theta[W(C) - W(A)] = \begin{cases} 1 & W(A) < W(C) \\ 0 & W(A) \geq W(C) \end{cases}$$

上面两项连接强度是最重要的, 但是理解一个句子, 有时候虽然该句子并不一定符合语法的要求, 且动词的使用也不一定正确, 但我们还是能够大致猜出其中的含义。比如“我和你”, 虽然这不是一个完整的句子, 但它还是有一定的意义的。只是读者还不能确定两个对象之间要做什么而已。这说明名词和名词、动词和名词、名词和动词之间的连接也还是有一定的意义的。故在计算句子强度的时候, 还要适当考虑一下 nn 结构和 nv 、 vn 结构对句子意义的影响。

295

(3) nn 结构强度

对于两个名词之间的属性比较, 如果两个名词词汇属性的相同, 则也可以增加该句子的句子强度数值。其计算公式如下:

300

$$P_{nn}(AVC) = \sum_{i,j} \{ \delta_{S_i(A), S_j(C)} \cdot \theta[W_j(C) - W_i(A)] \} \dots\dots\dots (3)$$

其中:

$$\delta_{S_i(A), S_j(C)} = \begin{cases} 1 & S_i(A) = S_j(C) \\ 0 & S_i(A) \neq S_j(C) \end{cases}$$

另外根据实际情况, 为了能够更好地抑制那些错误的句子, 也可以在 $W(A)$ 大于 $W(C)$ 的时候, 函数 $\theta[W_j(C) - W_i(A)]$ 取值为 -1。

305

(4) nv 和 vn 结构强度

对于动词与两个名词之间的连接, 则可以通过以下公式来计算句子强度:

$$P_{nv}(AVC) = \sum_{i,j} \{ \delta_{S_i(A), S_j(V)} \cdot \theta[0.5 - W_i(A)] \} \dots\dots\dots (4)$$

$$P_{vn}(AVC) = \sum_{i,j} \{\delta_{S_i(V), S_j(C)} \cdot \theta[W_i(C) - 0.5]\} \dots\dots\dots (5)$$

310 (5) 形容词结构强度

在一些句子中还经常使用形容词。这就涉及到形容词属性的确定方法。

形容词反映了名词的属性，形容词也是跟动词有关系的。通过分析形容词后面使用的动词的方式，可以确定形容词本身的属性。这里为了简单起见，只考虑形容词跟动词之间的关系。

315 形容词与动词搭配的计算公式为：

形容词如果在动词前面，则增加动词的前置属性。

如果动词 V 其包含的基本属性为：

前置属性：F

后置属性：B

320 若形容词 D 可以构成句子 DAVC，则经过学习以后，形容词 D 将获得属性：

$S_i(D)=DF$ ，位置为 $W_i(D)=0$

如果使用形容词 E 以后可以构成句子 AVEC，则经过学习以后，形容词 E 将获得属性：

$S_i(E)=EB$ ，位置为 $W_i(E)=1$

325 考虑到形容词用词不当对句子的影响比较严重，这里采用抑制的方法来降低形容词的错误应用。即如果形容词应用正确，句子的连接强度不变。然而如果形容词使用不正确，则将减少整个句子的连接强度。形容词与动词搭配的计算方法：

$$P_{anvn}(DAVC) = \sum_{i,j} \{\delta_{S_i(D), S_j(V)} \cdot \theta[W_i(D) - 0.5]\} \dots\dots\dots (6)$$

$$P_{nvan}(AVEC) = \sum_{i,j} \{\delta_{S_i(V), S_j(E)} \cdot \theta[0.5 - W_i(E)]\} \dots\dots\dots (7)$$

结合上述公式，可获得总体句子的连接强度，即句子强度为：

$$330 \quad P = \alpha P_{gram} + \beta P_{nvn} + \gamma P_{nn} + \lambda(P_{nv} + P_{vn}) - \eta(P_{anvn} + P_{nvan}) \dots\dots\dots (8)$$

上述系数反映了不同的连接强度。在实际的程序中，这些系数可以根据实际的情况来进行灵活的设置。

本文所构建的微型汉语系统中，各系数的数值为：

$\alpha = 0.3$

335 $\beta = 0.3$

$\gamma = 0.03$

$\lambda = 0.01$

$\eta = 0.1$

340 这里给出一个简单的例子来理解这一连接层的算法。该例子中，微型汉语系统的连接层尝试着理解句子“鸡吃虫”。

考虑到该微型汉语系统已经学习过若干个句子，且已经形成了表 2-1 所示的所有属性。

表 2-1 汉字属性实例 (Char 表示汉字，Si 表示第 i 个属性，Wi 表示第 i 个汉字属性位置)

345 Tab. 2-1 An example of the characters. (Char indicates the characters. Si indicates the i-th property, Wi indicates the position along with i-th property in the sentence)

Char	S1	W1	S2	W2	S3	W3	S4	W4	S5	W5	S6	W6	S7	W7
鸡	虫消	0	鸡饱	0	鸡消	1	狐饱	1	虫死	0	鸡吃	0		
吃	虫消	m	鸡饱	m	麦消	m	虫饱	m	鸡消	m	狐饱	m	草消	m

虫	虫消	1	鸡饱	1	麦消	0	虫饱	0	虫死	1	鸡吃	1	草消	0
---	----	---	----	---	----	---	----	---	----	---	----	---	----	---

由于该句子符合 $nv n$ 结构，因此该句子对应语法部分的句子强度可以这样计算：

$$P_{gram} = 1$$

下面再来计算“ $nv n$ 结构强度”。从表 2-1 可以看出，所有三个汉字都具有相同的两个属性：

{虫消；鸡饱}

而

$$W_i(\text{鸡}) < W_i(\text{虫})$$

$i=1, 2$

这样按照公式（2）可以计算出 $nv n$ 结构强度为：

$$P_{nv n} = 2$$

从表 2-1 可以看出所有的两个名词都具备 4 个相同的属性：

{虫消；鸡饱；虫死；鸡吃}

而：

$$W_i(\text{鸡}) < W_i(\text{虫})$$

$i=1, 2, 5, 6$

按照公式（3）可以计算出“ nn 结构强度”为：

$$P_{nn} = 4$$

汉字“鸡”和“吃”的相同属性为：

{虫消；鸡饱；鸡消；狐饱}

而：

$$W_1(\text{鸡}) = W_2(\text{鸡}) = 0$$

因此有：

$$P_{nv} = 2$$

汉字“吃”和“虫”的相同属性为：

{虫消；鸡饱；麦消；虫饱；草消}

而：

$$W_1(\text{虫}) = W_2(\text{虫}) = 1$$

因此有：

$$P_{vn} = 2$$

因为没有形容词，故：

$$P_{avn} + P_{van} = 0$$

使用公式（8）最终可以计算出该句子的句子强度为：

$$\begin{aligned} P &= \alpha + 2\beta + 4\gamma + 4\lambda \\ &= 0.3 + 0.6 + 0.12 + 0.04 \\ &= 1.06 \end{aligned}$$

该句子强度足够大，因此微型汉语系统通过该句子强度认定“鸡吃虫”这个句子是有意义的。当然如果微型汉语系统学习了更多的句子，该句子强度会有所变化。

2.2 微型汉语系统的规则层

微型汉语系统的规则层涉及到的内容比较复杂。其中包含了以下若干条规则：

1. 基本语法规则：指的是采用了什么样的语法结构。
2. 虚词的使用规则。规定如何使用虚词。
3. 标点符号规则。规定标点符号的使用方法。
4. 类别规则。规定对象类别的划分方法。

5. 词性规则。界定对象的词性。
6. 文章规则。规定输出文章所需遵循的结构。
7. 属性规则。将一个对象的属性转换成可以理解的字符。
8. 意义规则。从一个更高的层次上对微型汉语系统的表达方式进行限制。

3 微型汉语系统的构建实例

这里选择一个简单的生态系统,在该生态系统中,有肉食、草食两类动物、植物和食物。

另外还包含了满足动物和动物之间、动物和植物之间的运算关系的动词。用来描述动物属性的形容词。为了简单起见,这里不包括用来反映动作程度的副词。

3.1 生态系统

可以实现这种微型语言环境的系统很多,比如 Logo 语言中的海龟移动,生态系统等。在各种微型语言环境中,生态系统与我们的社会系统比较接近,更接近自然语言应用的环境。因此这里采用生态系统来构造这样的微型语言系统。

生态系统中一个著名的例子就是 Lotka-Volterra 模型。在该模型中,大鱼吃小鱼,小鱼吃水草。这个模型比较简单,但是通过计算可以证明该生态系统是具备稳定状态的。也就是说,只要有能量持续的输入,该系统不需要与外界交流物质就可以稳定存在。

为了满足微型语言系统的最低需求,需要将这个系统进行改进,并作适当的扩大。其中分成肉食动物、草食动物和植物等三大类。每一类都有相应的实例。例如肉食动物中包括了虎、鸡等。草食动物包括了牛、羊等。植物包括了草、麦等。

为了反映对象之间的关系,需要使用动词,包括吃、追、赶等。

而为了反映对象的属性,需要使用形容词,如肥、饿等。

3.2 词汇集合


所包含的对象及相互之间的关系如表 3-1 所示。其中包含了该系统中的所有汉字。

表 3-1 系统中所有的汉字
Tab. 3-1 All of the Characters in the system

类别	实例
肉食动物	虎、狐、鸡、狗
草食动物	牛、羊、虫
植物	草、麦
食物	肉
动词	吃、追、赶、抓
形容词	肥、饿

3.3 连接层中的词汇连接

对象之间的相互作用关系如图 2 所示。



420 图 2 微型汉语系统对象之间的相互关系
Fig. 2 The relationship among objectors in the MCS

3.4 规则层中的规则集合

425 该微型汉语系统中的规则层包含了这些规则：语法规则、虚词的使用规则、标点符号规则、类别规则、词性规则、文章规则、属性规则等。

3.5 表达层

使用文本输出装置输出自动生成的文章。

430 4 微型汉语系统的学习和词汇的生成

该系统可以通过输入适当的句子来进行学习。经过学习以后可以在连接层形成个汉字之间的连接。

4.1 汉字属性的生成

435 首先设置一个空表，在该表中只有动词具备基本的前置和后置属性，其他的词汇属性暂时为空。动词的前置和后置属性为随机设置。表 4-1 显示了所有汉字的初始属性。

表 4-1 所有汉字的初始属性
Tab. 4-1 The initial properties for all characters

汉字	类别	词性	属性	位置	属性	位置
吃	动作	v	aa	b	ab	f
虎	动物	n				
牛	动物	n				
麦	植物	n				

鸡	动物	n					
虫	动物	n					
狐	动物	n					
狗	动物	n					
羊	动物	n					
抓	词性	v	ac	b	ad	f	
追	词性	v	ae	b	af	f	
赶	动作	v	ai	b	cj	f	
肉	食物	n					
草	植物	n					
饿	状态	a					
肥	状态	a					

440

直接输入一个符合 nv_n 结构的句子以后，将按照 2.1.1 中的运算规则为每个汉字添加相应的属性。例如学习了“牛吃草”这个句子以后，将分别在“牛”、“吃”、“草”这三个汉字的属性中添加相应的属性，如表 4-2 所示：

445

表 4-2 学习了句子“牛吃草”以后的汉字属性变化情况

Tab. 4-2 The character's properties after learning the sentence "Cows eat grass"

汉字	类别	词性	属性	位置	属性	位置	属性	位置	属性	位置
吃	动作	v	aa	b	ab	f	牛 ab	m	草 aa	m
牛	动物	n	牛 ab	0	草 aa	0				
草	植物	n	牛 ab	1	草 aa	1				

4.2 句子意义的判断

450

经过了足够数量句子样本的学习以后，利用 2.1.2 中的公式就可以在连接层对所有句子的意义进行判断。用图 2 中涉及到的所有不包含形容词的句子进行学习，这样用来学习的句子一共包括了 52 条，如表 4-3 所示。

表 4-3 用来学习的所有句子

Tab. 4-3 All of the sentences can be used for learning

序号	句子	序号	句子	序号	句子	序号	句子
1	虎吃狗	14	虎追牛	27	狐抓鸡	40	狗追虫
2	虎追狗	15	虎赶牛	28	鸡吃虫	41	狗赶虫
3	虎赶狗	16	虎抓牛	29	鸡追虫	42	狗抓虫
4	虎抓狗	17	虎吃羊	30	鸡抓虫	43	狗追牛
5	虎吃狐	18	虎追羊	31	鸡赶虫	44	狗赶牛
6	虎追狐	19	虎赶羊	32	鸡吃草	45	狗追羊
7	虎赶狐	20	虎抓羊	33	鸡吃麦	46	狗赶羊
8	虎抓狐	21	虎吃肉	34	狗追狐	47	牛吃草
9	虎吃鸡	22	狐吃肉	35	狗赶狐	48	牛吃麦
10	虎追鸡	23	狗吃肉	36	狗抓狐	49	羊吃草
11	虎赶鸡	24	狐吃鸡	37	狗追鸡	50	羊吃麦
12	虎抓鸡	25	狐追鸡	38	狗赶鸡	51	虫吃草

13	虎吃牛	26	狐赶鸡	39	狗抓鸡	52	虫吃麦
----	-----	----	-----	----	-----	----	-----

455

学习以后输出的句子强度比较高的句子如表 4-4 所示。

表 4-4 连接强度比较高的句子
Tab. 4-4 The sentences that have greater SS (Sentence Strength)

序号	句子	句子强度	序号	句子	句子强度	序号	句子	句子强度	序号	句子	句子强度
1	虎吃羊	1.21	14	虎抓狐	1.2	27	鸡抓虫	1.14	40	狗赶羊	1.04
2	虎吃牛	1.21	15	虎抓狗	1.2	28	鸡赶虫	1.14	41	狗赶牛	1.04
3	虎吃鸡	1.21	16	虎赶羊	1.2	29	狗追鸡	1.1	42	虎吃肉	1.03
4	虎吃狐	1.21	17	虎赶牛	1.2	30	狗追狐	1.1	43	虫吃麦	1.01
5	虎吃狗	1.21	18	虎赶鸡	1.2	31	狗追虫	1.1	44	虫吃草	1.01
6	虎追羊	1.2	19	虎赶狐	1.2	32	狗抓鸡	1.1	45	羊吃麦	0.99
7	虎追牛	1.2	20	虎赶狗	1.2	33	狗抓狐	1.1	46	羊吃草	0.99
8	虎追鸡	1.2	21	鸡吃虫	1.17	34	狗抓虫	1.1	47	牛吃麦	0.99
9	虎追狐	1.2	22	狐追鸡	1.16	35	狗赶鸡	1.1	48	牛吃草	0.99
10	虎追狗	1.2	23	狐抓鸡	1.16	36	狗赶狐	1.1	49	鸡吃麦	0.99
11	虎抓羊	1.2	24	狐赶鸡	1.16	37	狗赶虫	1.1	50	鸡吃草	0.99
12	虎抓牛	1.2	25	狐吃鸡	1.16	38	狗追羊	1.04	51	狐吃肉	0.98
13	虎抓鸡	1.2	26	鸡追虫	1.14	39	狗追牛	1.04	52	狗吃肉	0.98

460

表 4-4 中显示的都是已经学习过的句子。另外值得注意的是，那些在图 2 中没有标记出来的关系，但在已经学习的系统中可以获得比较高句子强度的句子，也还是有一定意义的。表 4-5 列出了句子强度超过了 0.37 的句子。

465

表 4-5 没有学习过但句子强度较大的句子
Tab. 4-5 The greater SS sentences that have not been learned

句子	句子强度	句子	句子强度
狗吃鸡	0.5	虎抓肉	0.42
狗吃狐	0.5	虎赶肉	0.42
狗吃虫	0.5	狐追肉	0.38
狗抓羊	0.44	狐抓肉	0.38
狗抓牛	0.44	狐赶肉	0.38
狗吃羊	0.44	狗追肉	0.38
狗吃牛	0.44	狗抓肉	0.38
虎追肉	0.42	狗赶肉	0.38

470

可以看出这些获得比较高的连接强度的句子也还是有一定的意义的。而部分连接强度比较低的句子如表 4-6 所示。

475

表 4-6 部分连接强度比较低的句子
Tab. 4-6 Some sentences that have smaller sentence strength

句子	句子强度
羊抓虎	0.3
肉追羊	0.3
肉赶虎	0.3
麦抓牛	0.3
鸡追羊	0.3
草追羊	0.3
草赶虫	0.3

480 可以初步判断, 在该系统中, 如果相关汉字在获得了足够多的句子的学习以后, 就可以对同类型的句子给出比较高的连接强度。

其原因可以通过下面的例子来进行分析。

对于句子“虎赶牛”, 经过了学习以后, 会有:

$$S_i(\text{虎}) = S_j(\text{赶}) = S_k(\text{牛})$$

485 $W_i(\text{虎}) < W_k(\text{牛})$

继续学习句子“虎追牛”, 经过学习以后, 有:

$$S_i(\text{虎}) = S_j(\text{追}) = S_k(\text{牛})$$

$$W_i(\text{虎}) < W_k(\text{牛})$$

继续学习句子“虎吃羊”, 有:

490 $S_{i'}(\text{虎}) = S_{j'}(\text{吃}) = S_{k'}(\text{羊})$

$$W_{i'}(\text{虎}) < W_{k'}(\text{羊})$$

上述三个句子的学习, 将形成“虎吃 F”、“羊吃 B”、“虎赶 F”、“牛赶 B”、“虎追 F”、“牛追 B”的属性。该属性应用到类似的句子中, 将可以提高这些句子的连接强度。

例如“虎吃牛”这个句子还没有学习过, 但是如果学习了“虎吃鸡”、“虎吃羊”、“虎吃狗”以后, 其中包括“虎”与“吃”的前置属性组合在一起的相同属性, 再加上三个宾语名词和“吃”组合在一起形成的相同属性, 这样将形成一共 $P_{nv}=4$ 个相同属性。

而通过“虎追牛”和“虎赶牛”的学习, 将形成 4 个相同的属性, 且顺序也符合要求。故 $P_{nn}=4$, 意味着这两个名词之间有完全相同的属性。

故可以计算出:

500 $P(\text{虎吃牛}) = \alpha + 4\gamma + 4\lambda = 0.46$

也就是说, 在学习的过程中, 如果能够尽可能多地学习包含相关汉字的不同句子, 则程序就越能够正确判断由该汉字构成的句子的正确性。

为了进一步了解程序对句子意义的理解能力, 这里选择表 4-4 中序号为奇数的句子进行学习, 以便了解偶数行句子的连接强度是否可以获得自动的提升。

505 表 4-7 显示已经学习过的句子的句子强度。从表中可以看出, 由于学习的句子数量减少了, 这些已经学习过的句子的句子强度相比表 4-4 中的数据都有所下降。

510

表 4-7 已经学习过的句子的句子强度

Tab. 4-7 The SS of the sentences that have been learned

句子	句子强度	句子	句子强度
虎抓鸡	1.09	狗赶牛	1.07
虎吃鸡	1.09	狗赶虫	1.07
虎抓羊	1.08	虎追狐	1.06
虎吃羊	1.08	虎赶狐	1.06
狐抓鸡	1.08	狗追鸡	1.06
虎抓狗	1.07	狗赶鸡	1.06
虎追牛	1.07	鸡抓虫	1.05
虎赶牛	1.07	狗抓狐	1
虎吃狗	1.07	鸡吃麦	0.99
鸡吃虫	1.07	牛吃麦	0.98
狐吃鸡	1.07	虫吃麦	0.98
狗追牛	1.07	狐吃肉	0.98
狗追虫	1.07	羊吃麦	0.98

而表 4-4 中那些没有学习过的偶数行的句子,将自动获得的句子强度数值如表 4-8 所示:

表 4-8 没有学习过的偶数行句子的句子强度数值

Tab. 4-8 The SS of the sentences labeled as the even number in Tab. 4-4

句子	句子强度	句子	句子强度
虎吃牛	0.46	鸡赶虫	0.45
虎吃狐	0.47	狗追狐	0.4
虎追羊	0.45	狗抓鸡	0.48
虎追鸡	0.46	狗抓虫	0.46
虎追狗	0.46	狗赶狐	0.4
虎抓牛	0.46	狗追羊	0.33
虎抓狐	0.47	狗赶羊	0.33
虎赶羊	0.45	虎吃肉	0.34
虎赶鸡	0.46	虫吃草	0.32
虎赶狗	0.46	羊吃草	0.32
狐追鸡	0.44	牛吃草	0.32
狐赶鸡	0.44	鸡吃草	0.33
鸡追虫	0.45	狗吃肉	0.31

表 4-8 中所有句子的句子强度平均值为: 0.412, 标准差: 0.062

而那些没有学习过, 虽符合语法规则, 但不在表 4-4 中的句子的句子强度平均值为: 0.323, 标准差为: 0.023

520

可以判断已经学习过的句子, 是能够启发那些有意义的句子的联想的。

从实验的结果来看, 除了已经学习过的句子可以获得较高的句子强度以外, 那些没有学习过的, 但是有意义的句子也同样可以获得较高的句子强度。证明这一系统还是能够利用已经学习过的少量样本, 对句子的意义进行归类。

另外还可以考虑增加形容词的问题。增加形容词以后, 句子的表达形式将更加丰富。

525 由于本文已经做了一个简单的假设，即形容词只和动词之间相互结合，故所需要学习的句子比较简单。这里让程序学习句子：“饿虎吃肥羊”，这样“饿”、“肥”和“吃”三个汉字就可以增加相应的属性。

在表 4-7 学习的基础上，添加两个形容词“饿”和“肥”，并学习句子“饿虎吃肥羊”，这样获得句子强度排行前五十二位的结果如表 4-9 所示。

530

表 4-9 增加形容词以后句子权值比较高的句子

Tab. 4-9 The sentences that have high SS after adding the adjectives

句子	权重	句子	权重	句子	权重	句子	权重
虎抓鸡	1.09	虎抓羊	1.08	狐抓鸡	1.08	饿虎抓肥狗	1.07
饿虎抓鸡	1.09	饿虎抓羊	1.08	饿狐抓鸡	1.08	肥虎抓狗	1.07
虎抓饿鸡	1.09	虎抓饿羊	1.08	狐抓饿鸡	1.08	虎抓肥狗	1.07
饿虎抓饿鸡	1.09	饿虎抓饿羊	1.08	饿狐抓饿鸡	1.08	肥虎抓饿狗	1.07
饿虎抓肥鸡	1.09	饿虎抓肥羊	1.08	饿狐抓肥鸡	1.08	肥虎抓肥狗	1.07
肥虎抓鸡	1.09	肥虎抓羊	1.08	肥狐抓鸡	1.08	虎追牛	1.07
虎抓肥鸡	1.09	虎抓肥羊	1.08	狐抓肥鸡	1.08	饿虎追牛	1.07
肥虎抓饿鸡	1.09	肥虎抓饿羊	1.08	肥狐抓饿鸡	1.08	虎追饿牛	1.07
肥虎抓肥鸡	1.09	肥虎抓肥羊	1.08	肥狐抓肥鸡	1.08	饿虎追饿牛	1.07
虎吃鸡	1.09	虎吃羊	1.08	虎抓狗	1.07	饿虎追肥牛	1.07
饿虎吃鸡	1.09	饿虎吃羊	1.08	饿虎抓狗	1.07	肥虎追牛	1.07
饿虎吃肥鸡	1.09	饿虎吃肥羊	1.08	虎抓饿狗	1.07	虎追肥牛	1.07
虎吃肥鸡	1.09	虎吃肥羊	1.08	饿虎抓饿狗	1.07	肥虎追饿牛	1.07

535 可以看出，在句子强度排列比较靠前的跟“吃”有关的句子中，形容词的使用都是正确的。

4.3 同 N-gram 模型的比较

当然我们也可以尝试使用 N-gram 来解决这一问题。由于在上述微型汉语系统中，句子的最大长度为 5 个字符，因此我们可以使用 5-gram 模型来解决这一问题。

540 如果再不考虑形容词，则句子的最大长度只有 3 个字符，因此只需要使用 Tri-gram 模型就可以了。句子的几率可以按照公式 (9) 来进行计算：

$$P(S)=P(C1C2C3)=P(C1)P(C2|C1)P(C3|C1C2) \dots\dots\dots (9)$$

公式 (9) 中的 S 表示一个句子。Ci 表示一个汉字字符(i=1,2,3.....)。

几率 P 相当于本文提出的句子强度。

545 由于微型汉语系统中的汉字字数有限，因此可以利用公式 (9) 进行严格计算，不需要采用近似的方法。

不考虑形容词，该微型汉语系统一共包含了 14 各汉字。如果系统不学习任何的句子，则单个汉字出现的几率为 1/14，而二阶以上的条件概率则为零。不过随着句子不断学习新的句子，这些概率会不断发生变化。

这里利用表 4-4 中的句子来进行学习，假设每个句子的学习次数是相同的，则经过学习以后每个汉字的二阶和三阶条件概率将不再为零。此时单个汉字出现的概率如表 4-10 所示。

其中对于汉字 C_i 而言，其出现的次数为 N_i ，则汉字 C_i 出现的概率的计算公式如公式 (10) 所示。

$$P(C_i) = \frac{N_i + 1}{\sum_{j=1}^{14} (N_j + 1)} \dots\dots\dots (10)$$

555

表 4-10 单个汉字的几率

Tab.4-10 The probability of a single character

汉字	几率	汉字	几率
吃	0.12	狗	0.11
虎	0.12	羊	0.04
牛	0.07	抓	0.08
麦	0.05	追	0.07

560

而二阶和三阶条件概率则意味着前一个或两个汉字出现的条件下，该汉字的概率大小。比如“虎吃”出现的概率，反映的是在汉字“虎”出现以后，“吃”字出现的概率，表示为 $P(\text{吃}|\text{虎})$ 。

由于两个汉字的组合一个有

$$14 \times 14 = 196 \text{ (个)}$$

表 4-11 显示在系统中的每一个句子都被学习一次以后，不为零的二阶条件概率。

565

表 4-11 二阶条件几率

Tab. 4-11 Second order conditional probabilities

汉字	几率	汉字	几率	汉字	几率
P(吃 虎)	0.015306	P(鸡 追)	0.005102	P(羊 吃)	0.005102
P(吃 牛)	0.005102	P(鸡 赶)	0.005102	P(羊 抓)	0.005102
P(吃 鸡)	0.010204	P(虫 吃)	0.005102	P(抓 虎)	0.015306
P(吃 虫)	0.005102	P(虫 抓)	0.005102	P(抓 鸡)	0.005102
P(吃 狐)	0.010204	P(虫 追)	0.005102	P(抓 狐)	0.005102
P(吃 羊)	0.005102	P(虫 赶)	0.005102	P(抓 狗)	0.005102
P(牛 追)	0.010204	P(狐 抓)	0.005102	P(追 虎)	0.010204
P(牛 赶)	0.010204	P(狐 追)	0.005102	P(追 狗)	0.015306
P(麦 吃)	0.020408	P(狐 赶)	0.005102	P(赶 虎)	0.010204
P(鸡 吃)	0.010204	P(狗 吃)	0.005102	P(赶 狗)	0.015306
P(鸡 抓)	0.010204	P(狗 抓)	0.005102	P(肉 吃)	0.005102

570

而在不考虑形容词的条件下，三个汉字的组合一共有

$$14^3 = 2744 \text{ (个)}$$

则在每个句子只学习一次的条件下，每个句子出现的概率为：

$$\frac{1}{2744} = 0.000364$$

按照公式 (9) 计算学习以后的三阶条件概率，则不为零的三阶条件概率如表 4-12 所示。

575

表 4-12 三阶条件概率

Tab. 4-12 Third order conditional probabilities

汉字	几率	汉字	几率
P(鸡 虎抓)	4.3827E-06	P(牛 狗赶)	3.9843E-06
P(鸡 虎吃)	4.3827E-06	P(虫 狗赶)	3.9843E-06
P(羊 虎抓)	4.3827E-06	P(狐 虎追)	2.9218E-06
P(羊 虎吃)	4.3827E-06	P(狐 虎赶)	2.9218E-06
P(鸡 狐抓)	9.2967E-07	P(鸡 狗追)	3.9843E-06
P(狗 虎抓)	4.3827E-06	P(鸡 狗赶)	3.9843E-06
P(牛 虎追)	2.9218E-06	P(虫 鸡抓)	1.3281E-06
P(牛 虎赶)	2.9218E-06	P(狐 狗抓)	1.3281E-06
P(狗 虎吃)	4.3827E-06	P(麦 鸡吃)	2.6562E-06
P(虫 鸡吃)	2.6562E-06	P(麦 牛吃)	7.9686E-07
P(鸡 狐吃)	1.8593E-06	P(麦 虫吃)	7.9686E-07
P(牛 狗追)	3.9843E-06	P(肉 狐吃)	1.8593E-06
P(虫 狗追)	3.9843E-06	P(麦 羊吃)	5.3124E-07

从表 4-12 可以看出，只有那些已经被学习过的句子，其三阶条件概率才不会为零。这说明 Tri-gram 模型具备记住所学习内容的能力，但是不具备判断句子意义的能力的。

580

现在我们只考虑 Bi-gram 模型。因为通过该模型才有可能对那些没有学习过的句子进行计算以后，获得整个句子出现概率不为零的结果。Bi-gram 模型计算的公式如公式（11）所示。

$$P(S) = P(C1)P(C2 | C1)P(C3 | C2) \dots \dots \dots (11)$$

585

按照公式（11）计算以后，即便是没有学习过的句子也可以获得不为零的结果。结果显示在表 4-13 中。

从表 4-13 的结果来看，概率不为零的句子增加到 100 个。其中几率最大的句子为“虎吃麦”。但是这样的句子虽然符合语法，却没有意义。因为在这个微型汉语模型中，老虎是不吃麦子等植物的。另外我们也可以注意到，其中一些有意义的句子反而获得比较低的概率。比如有意义的句子“虎赶牛”的概率就要低于无意义的句子“吃鸡吃”。这是不正确的。

590

表 4-13 仅考虑 Bi-gram 模型的条件下载句子的几率

Tab. 4-13 Some of the probabilities of the sentences only considering the Bi-gram model

句子	几率	句子	几率
虎吃麦	0.000245433	虎赶牛	8.18112E-05
虎吃鸡	0.000122717	抓鸡吃	5.20616E-05
吃鸡吃	8.18112E-05	虫吃狗	1.11561E-05
虎追牛	8.18112E-05	羊吃肉	7.43738E-06

595

由上述结果我们可以得出结论，本文所提出的微型汉语模型在判断句子的意义方面明显好于 N-gram 模型。或者说 N-gram 语言模型基本上不具备句子意义判断能力。尽管目前在汉语拼音整句输入法中 N-gram 模型应用的很广泛。

4.4 词汇的生成

600

由于有意义的句子多次使用，将使一些汉字之间的连接得以加强。这些得以加强的连接可望成为产生由多个汉字组成的汉语词汇的基础。

这里采用比较简单的方法来判断连接的强度。即在所生成的所有句子中，那些出现概率最多的两个以上汉字的组合，就可称之为词汇。

利用增加了形容词以后的句子强度比较高的句子，对它们进行统计，可以发现，一些两个以上汉字的组合在句子中出现的统计概率非常高。

605 其中用来进行分析的句子，其句子强度达到 0.45 以上。因为从实验结果来看，连接强度在 0.44 以上的句子基本正确。这样的句子一共有 385 个，文本总字数为 2047。

另外在计算词汇出现频率的时候，要剔除一些经常使用的动词或形容词跟名词之间的结合。比如“吃”字经常跟其他的名词结合在一起，则诸如“虎吃”、“鸡吃”之类的组合就要适当进行抑制。

610 对于由汉字 A 和 B 组成的词汇 AB，该词汇在文章中出现的频度的具体计算公式为：

$$F = n(AB) \cdot \tau^{\left[\frac{n(A)+n(B)}{2} - n(AB)\right]}$$

其中 n(AB)为 AB 组合在文章中出现的具体次数。n(A)和 n(B)分别为汉字 A 和汉字 B 在文章中出现的次数。τ 为抑制参数。这里取 τ=0.98。

例如汉字 A 和汉字 B 各出现了 5 次，AB 组合也出现了 5 次，则：

615
$$\frac{n(A)+n(B)}{2} - n(AB) = 0$$

此时词汇出现的频度跟词汇出现的具体次数是相等的。

表 4-14 显示了出现频度较高的 52 个词汇。

620 表 4-14 系统产生的 52 个几率较大的词汇
Tab. 4-14 The top 52 higher frequency combinations

词汇	F	词汇	F	词汇	F	词汇	F
狗抓	10.18432	鸡吃	5.633417	狐抓	2.520492	赶虫	1.305329
虎追	8.080327	狐吃	5.633417	鸡抓	2.520492	抓牛	1.305329
虎赶	8.080327	吃饿	5.441576	肥狐	1.974541	饿牛	1.292462
吃肥	7.472788	虎吃	4.368716	牛吃麦	1.792199	鸡吃麦	1.245821
虎抓	7.37813	吃麦	3.643508	虫吃麦	1.792199	抓狐	1.228565
狗追	6.974464	饿狗	3.261172	羊吃麦	1.792199	狗吃	1.197681
狗赶	6.974464	鸡追	2.760374	饿狐	1.765566	抓虫	1.191893
抓饿	6.82571	鸡赶	2.760374	肥虫	1.616437	追鸡	1.134789
追饿	6.396112	狐追	2.760374	肥牛	1.473921	赶鸡	1.134789
赶饿	6.396112	狐赶	2.760374	饿虫	1.433009	抓鸡	1.036174
抓肥	6.295818	肥鸡	2.75367	追牛	1.429561	饿羊	1.021314
追肥	5.89957	肥狗	2.746436	赶牛	1.429561	肥羊	1.021314
赶肥	5.89957	饿鸡	2.53884	追虫	1.305329	吃肉	0.997568

当然由于该系统使用的汉字数量较少，且句子结构单一，所产生的词汇跟现代汉语词典收录的词汇有差异。不过这还是可以为我们的研究汉语词汇的形成提供一种新的方法。

625 5 文章的撰写

利用规则层的规定，可以着利用计算机来解释某一主题的含义。这里尝试利用中国古代“八股文”的形式，利用计算机来书写有一定意义的文章。

5.1 句子的联想

在文章的书写过程中，意义的联想是很重要的。由一个句子联想出另一个在意义上有关联的句子，整个思维过程就可以有效进行下去。

联想的算法如下：

1. 给出一个句子或词汇或汉字
2. 由句子或词汇或汉字获得多个属性
3. 从这些属性中随机选择一个属性
4. 再由该属性确定对应的主语名词、动词、宾语名词
5. 按照语法组成句子
6. 由动词确定形容词
7. 组成包含形容词的句子

5.2 文章的规则

整篇文章的规则包括了多个规则，这些规则分别是：

1. 基本语法规则：指的是采用了什么样的语法结构。

在语法规则方面，使用了基本的 SPO, DSPO, SZPO, DSZPO, SPDO, DSPDO, SZPDO, DSZPDO, SPOC, DSPOC, SZPOC, DSZPOC, SPDOC, DSPDOC, SZPDO, DSZPDO 等规则。

其中：主语（Subject，简称 S）、谓语（Predicate，简称 P）、宾语（Object，简称 O）、定语（Attribute，简称 D）、补语（Complement，简称 C）。

2. 虚词的使用规则：在形容词和名词之间增加虚词“之”或“的”。
3. 标点符号规则：遵照现代汉语的标点符号规定。
4. 类别规则：划分成了若干类，分别是动物、植物和食物等。
5. 词性规则，分别是名词、动词、形容词等。

6. 文章规则，利用类似于中国古代八股文的形式，将一篇文章的结构分成 8 个段落，分别是：破题、承题、起讲、开始、发展、高潮、退潮、结论。每个段落又有相应的规则进行对应。

7. 属性规则：当一个属性被多次使用以后，该属性也可以表达出特定的意义，可以用一个汉字来表示。

例如“吃”字的前置属性为 ab，后置属性为 aa

通过学习“牛吃草”的句子以后，三个汉字都可以获得属性“牛 ab”、“草 aa”

通过分析，可以用“ab=饱”来确定。这样“牛 ab”属性就可以表达为“牛饱”，这样看起来抽象的属性也可以被赋予一定的意义。如表 5-1 所示。

表 5-1 由属性规则确定下来的属性对应关系
Tab. 5-1 The relationship among the properties according to the properties' rule

动词	后置属性	前置属性
吃	消 aa	饱 ab
抓	失 ac	获 ad
追	跑 ae	赶 af
赶	禁 ai	拦 aj

而本例中，由动词“污”可以获得属性规则对应的汉字：脏。

8. 意义规则。

为了能够实现意义上的联系，这里使用另一个有关环保的微型汉语系统。

其相互之间的关系如下：

该微型汉语系统中包含的汉字为：

染、洁、饱、消

植、动、碳、水、氧、土、粪、环、气、食

生、放、造、吸、需、寻、争、污、净、清、护

各汉字之间的相互关系如图 3 所示。




图 3 环保微型汉语系统
Fig. 3 The environment protection MCS

上述微型汉语系统形成以后，利用 5.1 中的联想算法，由“污”字可以联想到“粪脏食”、“粪脏土”等句子。这些句子则可以用来指导整篇文章的生成。

5.3 自动生成文章实例

用一个汉字作为标题，利用上述规则，可以自动生成相应的文章。

自动生成的文章实例：

吃

破题：虎吃狐；羊吃草。

承题：虎饿；狐肥。羊饿；草肥。

起讲：故：虎饿、狐肥，虎吃狐。羊饿、草肥，羊吃草。

开始：虎：动物、狐：动物，虎吃狐。羊：动物、草：植物，羊吃草。虎吃狐，虎饱，狐消；羊吃草，羊饱，草消。

发展: 虎放粪。狐吸食。羊放粪。草净土。

高潮: 虎饱, 虎放粪多。狐消, 狐吸食少。羊饱, 羊放粪多。草消, 草净土少。

退潮: 谓之: 饿虎吃肥狐, 饱虎放粪多, 消狐吸食少。饿羊吃肥草, 饱羊放粪多, 消草净土少。

结束: 则: 粪脏食; 粪脏土。

685

可以利用一一对应关系, 将单个汉字对应为现代汉语中常用的多字词汇, 并在形容词和名词之间增加助词“的”, 可以看出文章的可读性得以明显改善:

有关“吃”的话题

老虎吃狐狸; 羔羊吃青草。

老虎饥饿; 狐狸肥美。羔羊饥饿; 青草肥美。

因此: 老虎饥饿、狐狸肥美, 老虎吃狐狸。羔羊饥饿、青草肥美, 羔羊吃青草。

老虎: 动物、狐狸: 动物, 老虎吃狐狸。羔羊: 动物、青草: 植物, 羔羊吃青草。老虎吃狐狸, 老虎饱了, 狐狸消失了; 羔羊吃青草, 羔羊饱了, 青草消失了。

老虎排放粪便。狐狸吸收食物。羔羊排放粪便。青草净化土壤。

老虎饱了, 老虎排放粪便多。狐狸消失了, 狐狸吸收食物少。羔羊饱了, 羔羊排放粪便多。青草消失了, 青草净化土壤少。

这就是: 饥饿的老虎吃肥美的狐狸, 饱了的老虎排放粪便多, 消失了的狐狸吸收食物少。饥饿的羔羊吃肥美的青草, 饱了的羔羊排放粪便多, 消失了的青草净化土壤少。

注意: 粪便弄脏食物; 粪便弄脏土壤。

690

从计算机生成的文章来看, 格式还比较机械。由于词汇量太少, 故生成的文章同人类所书写的文章相比, 还是有非常大的差距的。只是具备了基本的可读性而已。

6 结论

695

为了解决自然语言过于复杂的问题, 本文尝试构建了一个汉字数量很少的微型汉语系统。本文对该微型汉语系统进行分析, 并尝试将该语言系统分成四个层次, 分别是物理层、连接层、规则层和表达层, 这样形成了微型汉语系统的层次模型。该微型汉语系统可用来描述一个非常简单的生态系统。

700

在连接层上可以通过比较简单的算法促进汉字之间形成连接, 并通过编制程序来实现连接层上的功能。程序运行的结果表明, 通过学习适当的句子, 可以在汉字之间形成连接。这种汉字之间的连接可以用来实现对句子意义的判断。本研究还提供了一种研究汉语词汇是如何形成的新的方法。在本研究的案例中, 我们发现, 多字汉字词汇的形成并非完全随机的, 而是同单个汉字的意义有密切关系的。

705

另外本研究还尝试着利用中国古代八股文的形式, 将其应用到微型汉语系统中。这样微型汉语系统将可以输出字数较多、且内容有一定逻辑关系的文章。这种文章的输出利用了包括规则层、表达层等所有层次的功能。尽管规则层中的各种规则是人为制定出来的, 但相信通过构建更多的微型汉语系统, 比如文章系统、逻辑系统、虚词系统等, 可以自动产生出相应的规则出来, 这样计算机就可以在完全不需要人工干预的条件下自动对自然语言进行应

答。

从以上结果来看,传统的冯·诺依曼结构的计算机在处理自然语言方面还是有很大的潜力可挖的。

本研究的不足之处在于,计算机能够通过连接层在各种意义之间形成联系。但是计算机并不存在自主意识。微型汉语系统的词汇量必须达到一定的数量才能正确输出完整句子,这一数量的下限是多少,现在主要还是凭借经验来进行确定。另外对于一个句子,其句子强度究竟多大才是合适的?目前的研究来看,这是动态变化的数值。随着词库数量变化、学习句子数量的变化,会导致句子强度临界数值的变化起落很大。如何进行动态的判断,期待今后的研究能够给出正确的答案。

今后的研究,将扩大汉语系统的汉字个数,这样可以表达出更多的意义。另外也可以考虑由单个汉字经过学习之后,形成多字词汇,并将其应用到新的句子中,从而表达出内容更丰富的句子。

在本项研究中,规则是人为制定的。进一步的研究过程中,将尝试着利用系统生成各种规则。

另外也可以考虑在已有的层次模型基础上,增加“情感层”,期待利用情感层的制约,能够在计算机的自主意识方面有所进展。

[参考文献] (References)

- [1] 邢永康, 马少平. 统计语言模型综述[J]. 计算机科学, 2003, 30(009): 22 - 26.
- [2] 郭进. 统计语言模型及汉语音字转换的一些新结果[J]. 中文信息学报, 1993, 7(001): 18 - 27.
- [3] 周正宇, 李宗葛. 一种新的基于统计的词典扩展方法[J]. 中文信息学报, 2001, 15(005): 46 - 51.
- [4] 刘迁, 贾惠波. 中文信息处理中自动分词技术的研究与展望[J]. 计算机工程与应用, 2006, 42(3): 175 - 182.
- [5] 金凌, 吴文虎, 郑方, et al. 距离加权统计语言模型及其应用[J]. 中文信息学报, 2001, 15(6): 47 - 52.
- [6] 俞士汶, 朱学锋. 现代汉语语法信息词典[J]. 中文信息学报, 2001, 15(001): 59 - 64.
- [7] 俞士汶, 朱学锋, 王惠, et al. 现代汉语语法信息词典规格说明书[J]. 中文信息学报, 1996, 10(2): 1 - 22.
- [8] 俞士汶, 段慧明, 朱学锋, et al. 综合型语言知识库的建设与利用[J]. 中文信息学报, 2004, 18(5): 1 - 10.
- [9] 曹剑芬. 基于语法信息的汉语韵律结构预测[J]. 中文信息学报, 2003, 17(003): 41 - 46.
- [10] 周强, 张伟, 俞士汶. 汉语树库的构建[J]. 中文信息学报, 1997, 11(4): 42 - 51.
- [11] 俞士汶. 中文输入中语法分析技术的应用[J]. 中文信息学报, 1988, 2(3): 20 - 26.
- [12] 由丽萍, 范开泰, 刘开瑛. 汉语语义分析模型研究述评[J]. 中文信息学报, 2005, 19(006): 57 - 63.
- [13] 詹卫东, 常宝宝, 俞士汶. 基于词组本位语法的语义模型[J]. 载新加坡《中文与东方语言信息处理学会学报》, 1998, 8(1).
- [14] Stolcke A. SRILM-an extensible language modeling toolkit[C]//Proceedings of the international conference on spoken language processing. 2002, 2: 901-904.
- [15] Clarkson P, Rosenfeld R. Statistical language modeling using the CMU-Cambridge toolkit[C]//Fifth European Conference on Speech Communication and Technology. 1997.
- [16] Jelinek F, Merialdo B, Roukos S, et al. A dynamic language model for speech recognition[C]//Proceedings of the DARPA Workshop on Speech and Natural Language. 1991: 293-295.
- [17] Strong R D. Dynamic language model for speech recognition[M]. Google Patents, 1995.
- [18] MacKay D J ., Peto L C . A hierarchical Dirichlet language model[J]. Natural language engineering, 1995, 1(03): 289-308.
- [19] Teh Y W. A hierarchical Bayesian language model based on Pitman-Yor processes[C]//Proceedings of the 21st International Conference on Computational Linguistics and the 44th annual meeting of the Association for Computational Linguistics. 2006: 985-992.

- 755 [20] Gao J, Nie J Y, Wu G, et al. Dependence language model for information retrieval[C]//Proceedings of the 27th annual international ACM SIGIR conference on Research and development in information retrieval. 2004: 170–177.
- [21] Chelba C, Jelinek F. Structured language modeling[J]. Computer Speech & Language, 2000, 14(4): 283–332.
- [22] Lavrenko V, Croft W B. Relevance based language models[C]//Proceedings of the 24th annual international ACM SIGIR conference on Research and development in information retrieval. 2001: 120–127.
- 760 [23] Katz S. Estimation of probabilities from sparse data for the language model component of a speech recognizer[J]. Acoustics, Speech and Signal Processing, IEEE Transactions on, 1987, 35(3): 400–401.
- [24] Bahl L R, Brown P F, de Souza P V, et al. A tree-based statistical language model for natural language speech recognition[J]. Acoustics, Speech and Signal Processing, IEEE Transactions on, 1989, 37(7): 1001–1008.
- [25] Song F, Croft W B. A general language model for information retrieval[C]//Proceedings of the eighth international conference on Information and knowledge management. 1999: 316–321.
- 765 [26] Zhai C, Lafferty J. Model-based feedback in the language modeling approach to information retrieval[C]//Proceedings of the tenth international conference on Information and knowledge management. 2001: 403–410.
- [27] Hoyles C, Noss R, Adamson R. Rethinking the microworld idea[J]. Journal of educational computing research, 2002, 27(1): 29–53.
- 770 [28] Papert S. Microworlds: transforming education[J]. Artificial intelligence and education: University of Pittsburgh, USA.-Learning intelligence and education, 1987, 1: 79.